

Project Information

Project Name: KAI 2026 Passenger Forecasting Analytics

Created By: Data Engineering Team 5

Date: February 18, 2026

Version: 2.0

1. Executive Summary

1.1 Project Overview

- Tujuan Project: Mengembangkan sistem analitik untuk memprediksi lonjakan penumpang kereta api jarak jauh pada masa angkutan 2026. Mengembangkan sistem analitik visual (dashboard) dan model forecasting untuk memprediksi volume dan lonjakan penumpang kereta api per kategori layanan (Jabodetabek, MRT, Kereta Cepat, dll.) pada masa operasional tahun 2026.
- Scope Project: Ekstraksi dan pemrosesan historis data penumpang kereta (2024-2025), data tingkat inflasi ekonomi bulanan (M-to-M), integrasi worldwide calendar API (untuk menangkap pola musiman/liburan), serta pengembangan model Machine Learning menggunakan pendekatan regresi untuk analisis prediktif.
- Expected Outcomes:
 1. Model Machine Learning (Multiple Linear Regression dari pustaka Scikit-Learn) yang dilatih secara independen/spesifik untuk setiap kategori kereta.
 2. Dataset hasil prediksi komprehensif jumlah penumpang kereta api bulanan tahun 2026.
 3. Dashboard analitik interaktif yang menampilkan korelasi inflasi dan tren penumpang.
- Timeline: 3 bulan (Maret - Juni 2026)

1.2 Stakeholders

Project Owner: PT. Kereta Api Indonesia (Persero).

Team Members:

- Data Engineer: Edwin Nur Cahyo
- Data Analyst: Dheandra Khairunnisa P
- Project Manager: Julyo Firnanda

End Users:

- Dinas Perhubungan
- PT. Kereta Api Indonesia (Persero)
- Masyarakat umum & Pengamat Transportasi

2. Data Source Analysis

2.1 Data Pemerintah (bps.go.id)

2.1.1. Data Pemerintah (bps.go.id)

Source Details

- **Dataset Name:** Jumlah Penumpang Kereta Api (Ribuan Orang)
- **URL/Access Point:**

Dataset 2024:

<https://www.bps.go.id/id/statistics-table/2/NzIjMg==/jumlah-penumpang-kereta-api.html>

Dataset 2025:

<https://www.bps.go.id/id/statistics-table/2/NzIjMg==/jumlah-penumpang-kereta-api.html>

- **Data Owner:** BPS (Badan Pusat Statistik)
- **Update Frequency:** Bulanan

Data Analysis

- **Format Data:** CSV (2024 & 2025)
- **Volume Data:** 937 B
- **Time Coverage:** Januari 2024-Desember 2025.
- **Data Quality:**
 - Completeness: 100% (Tidak ada data kosong/missing values untuk rentang bulan Januari-Desember pada kedua tahun).
 - Accuracy: High (Rilis resmi BPS berdasarkan rekapitulasi operator transportasi).
 - Consistency: Good (format standard)

2.1.2. Inflasi Bulanan (M-to-M) (Persen), 2024-2026

Source Details

- **Dataset Name:** Inflasi Bulanan (M-to-M) (Persen), 2024 - 2026
- **URL/Access Point:**

Dataset 2024:

<https://www.bps.go.id/id/statistics-table/2/MSMy/inflasi-bulanan-m-to-m-.html>

Dataset 2025:

<https://www.bps.go.id/id/statistics-table/2/MSMy/inflasi-bulanan-m-to-m-.html>

Dataset 2026:

<https://www.bps.go.id/id/statistics-table/2/MSMy/inflasi-bulanan-m-to-m-.html>

- **Data Owner:** BPS (Badan Pusat Statiska)
- **Update Frequency:** Bulanan

Data Analysis

- **Format Data:** 3 File CSV terpisah (2024, 2025, 2026)
- **Volume Data:** ~12 KB (2024), ~12 KB (2025), dan ~8.6 KB (2026).
- **Time Coverage:** Januari 2024 hingga pencatatan terakhir Mei 2026 (bulan Juni-Desember 2026 masih bernilai kosong/strip)
- **Data Fields:** Kota Inflasi, Bulan (Januari - Desember). .
- **Data Quality:**
 - Completeness: 100% (untuk tahun 2024 dan 2025. Untuk dataset 2026, data valid hingga bulan Mei)
 - Accuracy: Tinggi (Digunakan sebagai standar indeks harga konsumen daerah).

2.2 Dataset Kaggle

Source Details

- **Dataset Name:** Inflation Rate in Asia
- **URL/Access Point:**
<https://www.kaggle.com/datasets/utkarshx27/inflation-rate-in-asia>
- **Creator/Publisher:** Utkarsh Singh
- **Last Update:** Updated 3 years ago

Data Analysis

- **Format Data:** CSV
- **Size & Dimensions:** 16.46 KB
- **Data Fields:**
 - RegionalMember (String)
 - Year (String)
 - Inflation (Decimal/Float)
 - Unit Of Measurement (String)
 - Subregion (String)
 - Country Code (String)
- **Quality Metrics:**
 - Missing Values: 4% (Data 2023 dan 2024 masih berupa forecast)
 - Data Types: Campuran numerik (Float/Integer) dan Kategorikal (String)
 - Consistency: High (Completeness · 100%, Credibility · 100%, Compatibility · 100%)
 - Documentation Quality: Excellent, includes data dictionary

2.3 Open Research Data

2.3.1. Referensi Domain: Prediksi Penumpang Kereta Api

Source Details

- **Dataset Name:** Kajian Penerapan Model Machine Learning / Multiple Linear Regression dalam Analisis Prediktif
- **Creator/Publisher:** Septian Dwi Cahyo, dkk. (STMIK YMI Tegal) / Journal of Artificial Intelligence and Digital Business (RIGGS), Vol. 4 No. 3 (2025)
- **Repository:** RIGGS - Journal of Artificial Intelligence and Digital Business (journal.ilmudata.co.id)
- **URL/Access Point:**
<https://journal.ilmudata.co.id/index.php/RIGGS/article/view/2061/1398>

Data Analysis

- **Format & Structure:** Journal, PDF (8 Halaman)
- **Data Quality:** Open Access, Peer-reviewed Journal.
- **Methodological Note for 2026 Project:** Jurnal ini menjadi referensi utama dalam pemahaman karakteristik dataset operasional kereta api. Penelitian pada jurnal ini membuktikan bahwa metode regresi linier sangat cocok digunakan untuk memprediksi mobilitas penumpang. Tim Data Engineering 5 kemudian mengimprovisasi pendekatan dari jurnal ini dengan meningkatkannya menjadi Multiple Linear Regression agar dapat memasukkan variabel makroekonomi (inflasi) sebagai fitur tambahan.

2.3.2. Referensi Metodologi: Regresi Linear Berganda pada Runtun Waktu (Time Series)

Source Details

- **Journal Title:** Implementasi Multiple Linear Regression Untuk Prediksi Data Runtun Waktu Menggunakan Pendekatan Machine Learning
- **Creator/Publisher:** Sri Ngudi Wahyuni, dkk. (Universitas Amikom Yogyakarta) / Jurnal Teknik Informatika dan Sistem Informasi (JATISI), Vol. 11, No. 2, Juni 2024
- **File Context:** Open research paper terindeks.
- **URL/Access Point:**
<https://jurnal.mdp.ac.id/index.php/jatisi/article/download/7878/1996>

Data Analysis

- **Format & Structure:** Journal, PDF (9 Halaman)
- **Data Quality:** Open Access, Peer-reviewed Journal.
- **Methodological Note for 2026 Project:** Jurnal ini memberikan validasi teoretis terhadap arsitektur Machine Learning yang dibangun oleh tim. Berdasarkan penelitian ini, terbukti bahwa Multiple Linear Regression memiliki keandalan tinggi untuk prediksi data runtun waktu (time series). Ini menjustifikasi langkah teknis tim yang memasukkan variabel Time_Index, Bulan_Angka, dan Inflasi ke dalam array fitur X_train untuk mendapatkan garis prediksi (y_pred) jumlah penumpang KAI hingga Desember 2026.